



ANÁLISIS DE DATOS

DESASTRES NATURALES

IMPACTO HUMANO Y ECONÓMICO

Soluciones aplicadas de Análisis de Datos y Aprendizaje Automático para entender y prever la magnitud destructiva de fenómenos naturales, con el fin de mitigar su impacto.

Equipo 2

Alejandra Eng
Ángel Bardon
Elena Blanco
Rafael De Marco

Fecha:

31/07/2023

Curso

Análisis de Datos
Escuela Digital
Fundación Adecco

An aerial photograph of a stunning Norwegian fjord. The scene is framed by towering, steep mountains covered in lush green forests. In the foreground, a vibrant blue river flows through a valley, its path marked by several small waterfalls and rapids. On the left bank, a cluster of traditional Norwegian houses with red roofs is nestled among the trees. To the right, more houses are visible along the shoreline. The water of the fjord is a deep turquoise color, reflecting the surrounding natural beauty.

Meter video real

OBJETIVOS

Académicos:

Adquirir conocimientos y habilidades de análisis de datos en un contexto real, mediante metodología CRISP-DM en el tema sobre desastres naturales.

Aplicación Práctica:

Conocer la magnitud y el impacto socio-económico para evaluar riesgos y diseñar soluciones prácticas como consultoría de inteligencia de negocio, diseño de dashboards y modelos predictivos.



EDA:
Terremotos
Sequías
Tormentas
Inundaciones



Modelo Predictivo:
Nivel de Destrucción



Modelo de Negocio

CONTENIDOS



Metodología y
dataset em-dat
Técnicas



EDA
Sequías



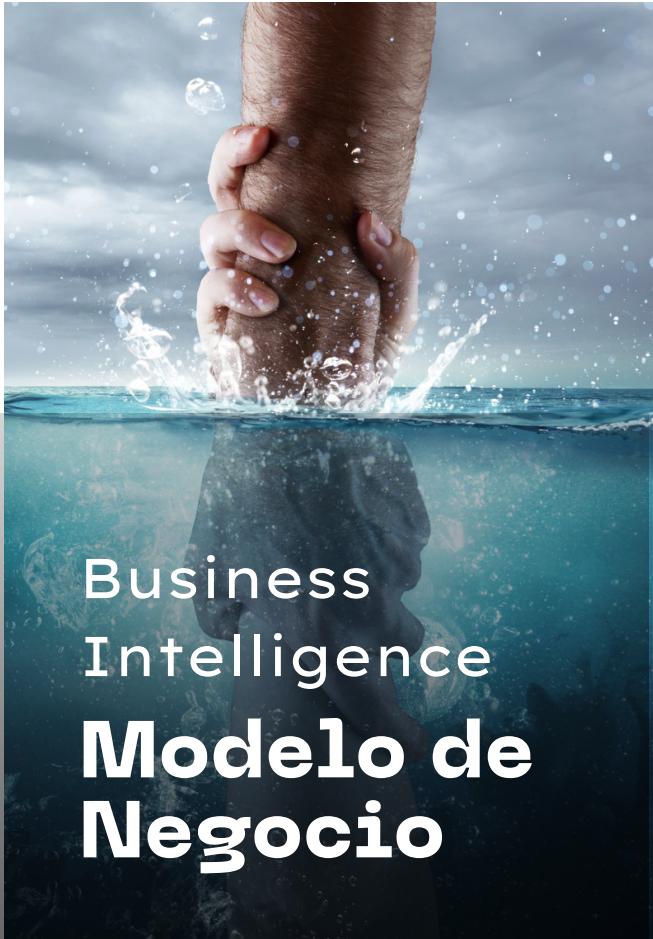
EDA
Tormentas



EDA
Terremotos



EDA y Modelo
Predictivo
Inundaciones



Business
Intelligence
**Modelo de
Negocio**

DESASTRES NATURALES

Base de datos



Fuente

Número de registros

26.004 filas

50 columnas

Grupos de desastres

Naturales

Tecnológicos
Complejos

Selección

16.636 filas

26 columnas

Período que abarca

122 años

1900 a 2023

Tipos de desastres

15 4

- Inundación
- Sequía
- Terremoto
- Tormenta

Subgrupos

Hidrológicos
Meteorológicos
Climatológicos
Geofísicos
Biológicos
~~Extra Terrestres~~

Ocurrencia
Fechas:
(Día, Mes y Año desagregados)
Inicio
Final

Geográfico
Continente
Región
País
Localidades
Coordinadas

Magnitud
Valores
Escalas

Impacto humano
Muertes
Afectados
Heridos
Afectados
Sin Hogar

Impacto económico
Daños
Costos
~~Reparación y Construcción a~~
~~Valor Actual~~

EM-DAT (Emergency Events Database)

Fuente: Centre for Research on the Epidemiology of Disasters (CRED), Univ. Católica de Lovaina (Bélgica).

Ocurrencia de desastres masivos desde 1900 hasta la actualidad.

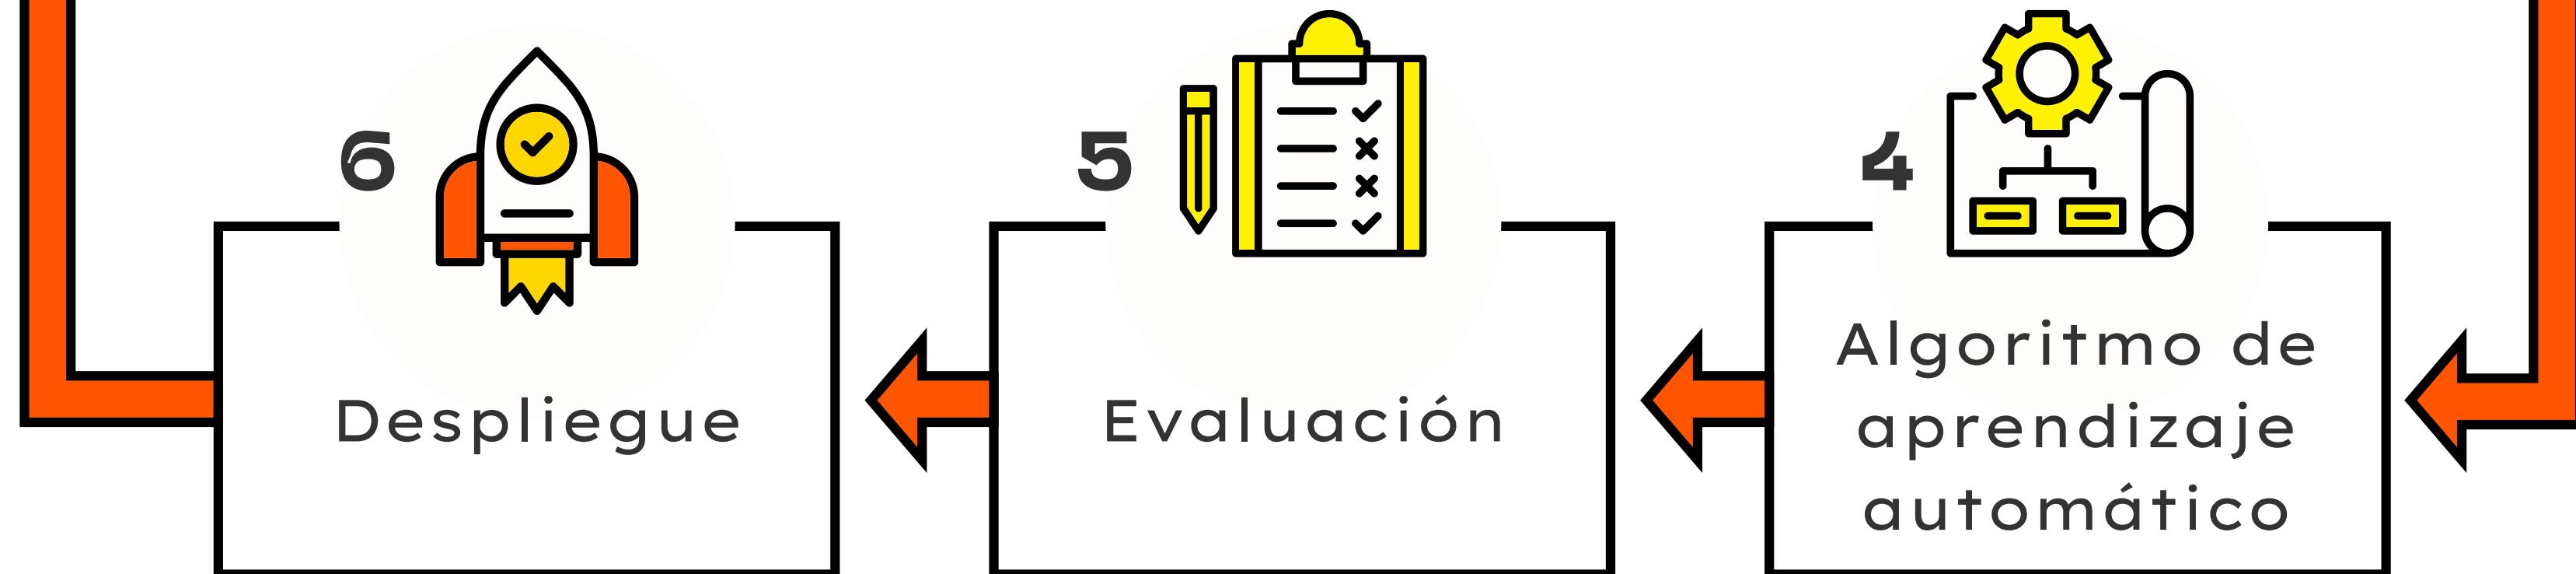
<https://www.emdat.be/>

<https://www.emdat.be/guidelines>

DESASTRES NATURALES

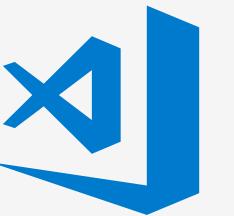


METODOLOGÍA CRISP-DM



DESASTRES NATURALES

PROCESO Y HERRAMIENTAS



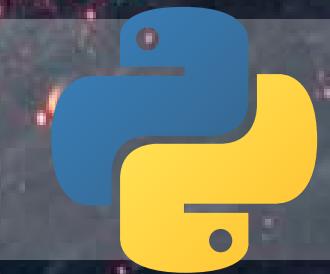
Comprensión del problema



Entendimiento de los datos



Preparación de datos

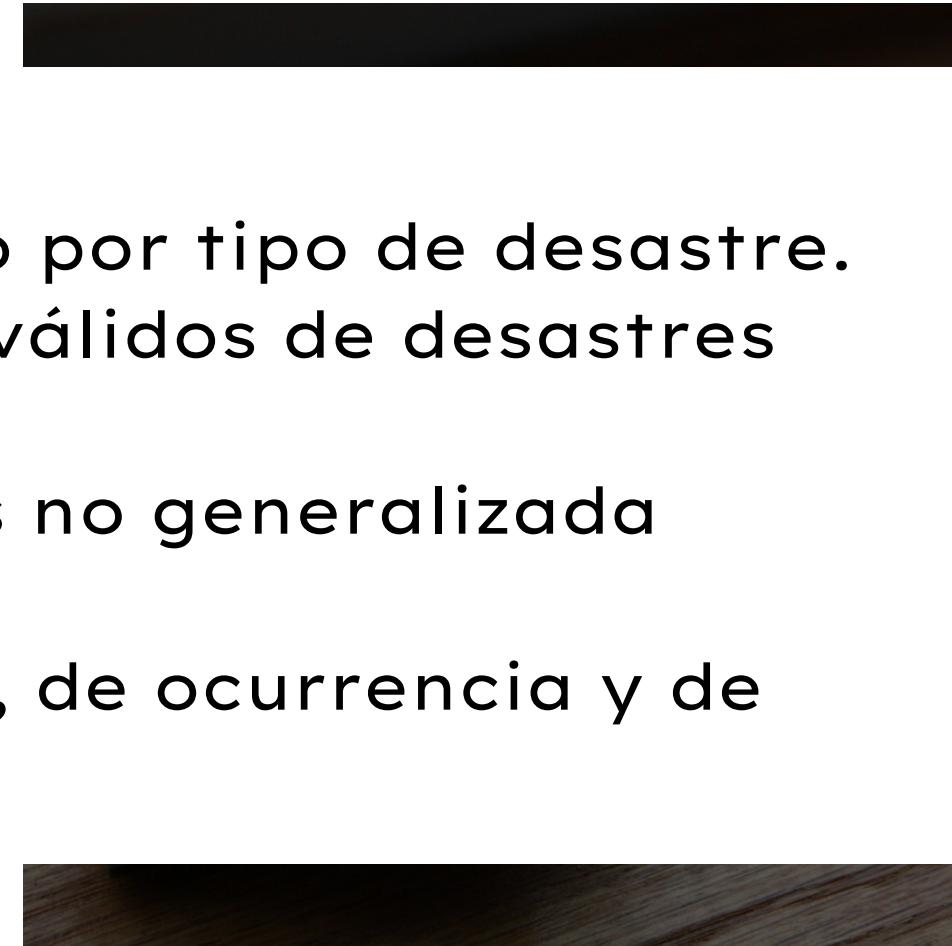


Modelado



PROCESOS GENERALES EDA

- Selección de 4 tipos de desastres.
- Limpieza y segmentación con filtro por tipo de desastre.
- Outliers no se eliminan: son datos válidos de desastres con grandes impactos.
- Limpieza y relleno de valores nulos no generalizada debido a naturaleza del dataset.
- Análisis de categorías geográficas, de ocurrencia y de impacto.



BUSINESS INTELLIGENCE

Gestión del socorro en casos de desastre



DISASTER RELIEF
BI Dashboard



ANÁLISIS DE DATOS. EQUIPO 2

Herramientas



Vídeo PowerBI
Sequías
máx 35 segundos

PowerBI

Terremotos

35 segundos

PowerBI
Tormentas
35 segundos

PowerBI

Inundaciones

35 segundos

DESASTRES NATURALES

CONCLUSIONES

GENERALES

- Los DN se están incrementando con el tiempo.
- Reducción paulatina en pérdidas de vidas humanas, probablemente debido a medidas de protección poblacional.
- A partir de los 60 se evidencia tendencia a la alza en daños, que coincide con el aumento en la frecuencia de desastres.
- El análisis de datos es fundamental para organizar planes de emergencia frente a la repetición de desastres naturales.

SÍNTESIS DE IMPACTO:

**MUERTES
DESCENSO**

**AFFECTADOS
AUMENTO**

**DAÑOS
AUMENTO**



DESASTRES NATURALES

CONCLUSIONES

ESPECÍFICAS POR TIPO DE DESASTRE

Sequías:

- Las más letales.
- Incremento en sucesos y reducción del período entre los mismos.

Terremotos:

- Frecuencia irregular. Tendencia a la alza hasta 2004.
- A partir de los 70, incremento de daños cuando magnitud supera 8.

Tormentas:

- Top de 10 años con máximo record: 9 de los años son del SXXI.
- Picos de afectados cada 5 ó 6 años.

Inundaciones:

- Las más habituales.
- Producen más afectados.



MACHINE LEARNING

Modelo predictivo de Nivel de Destrucción



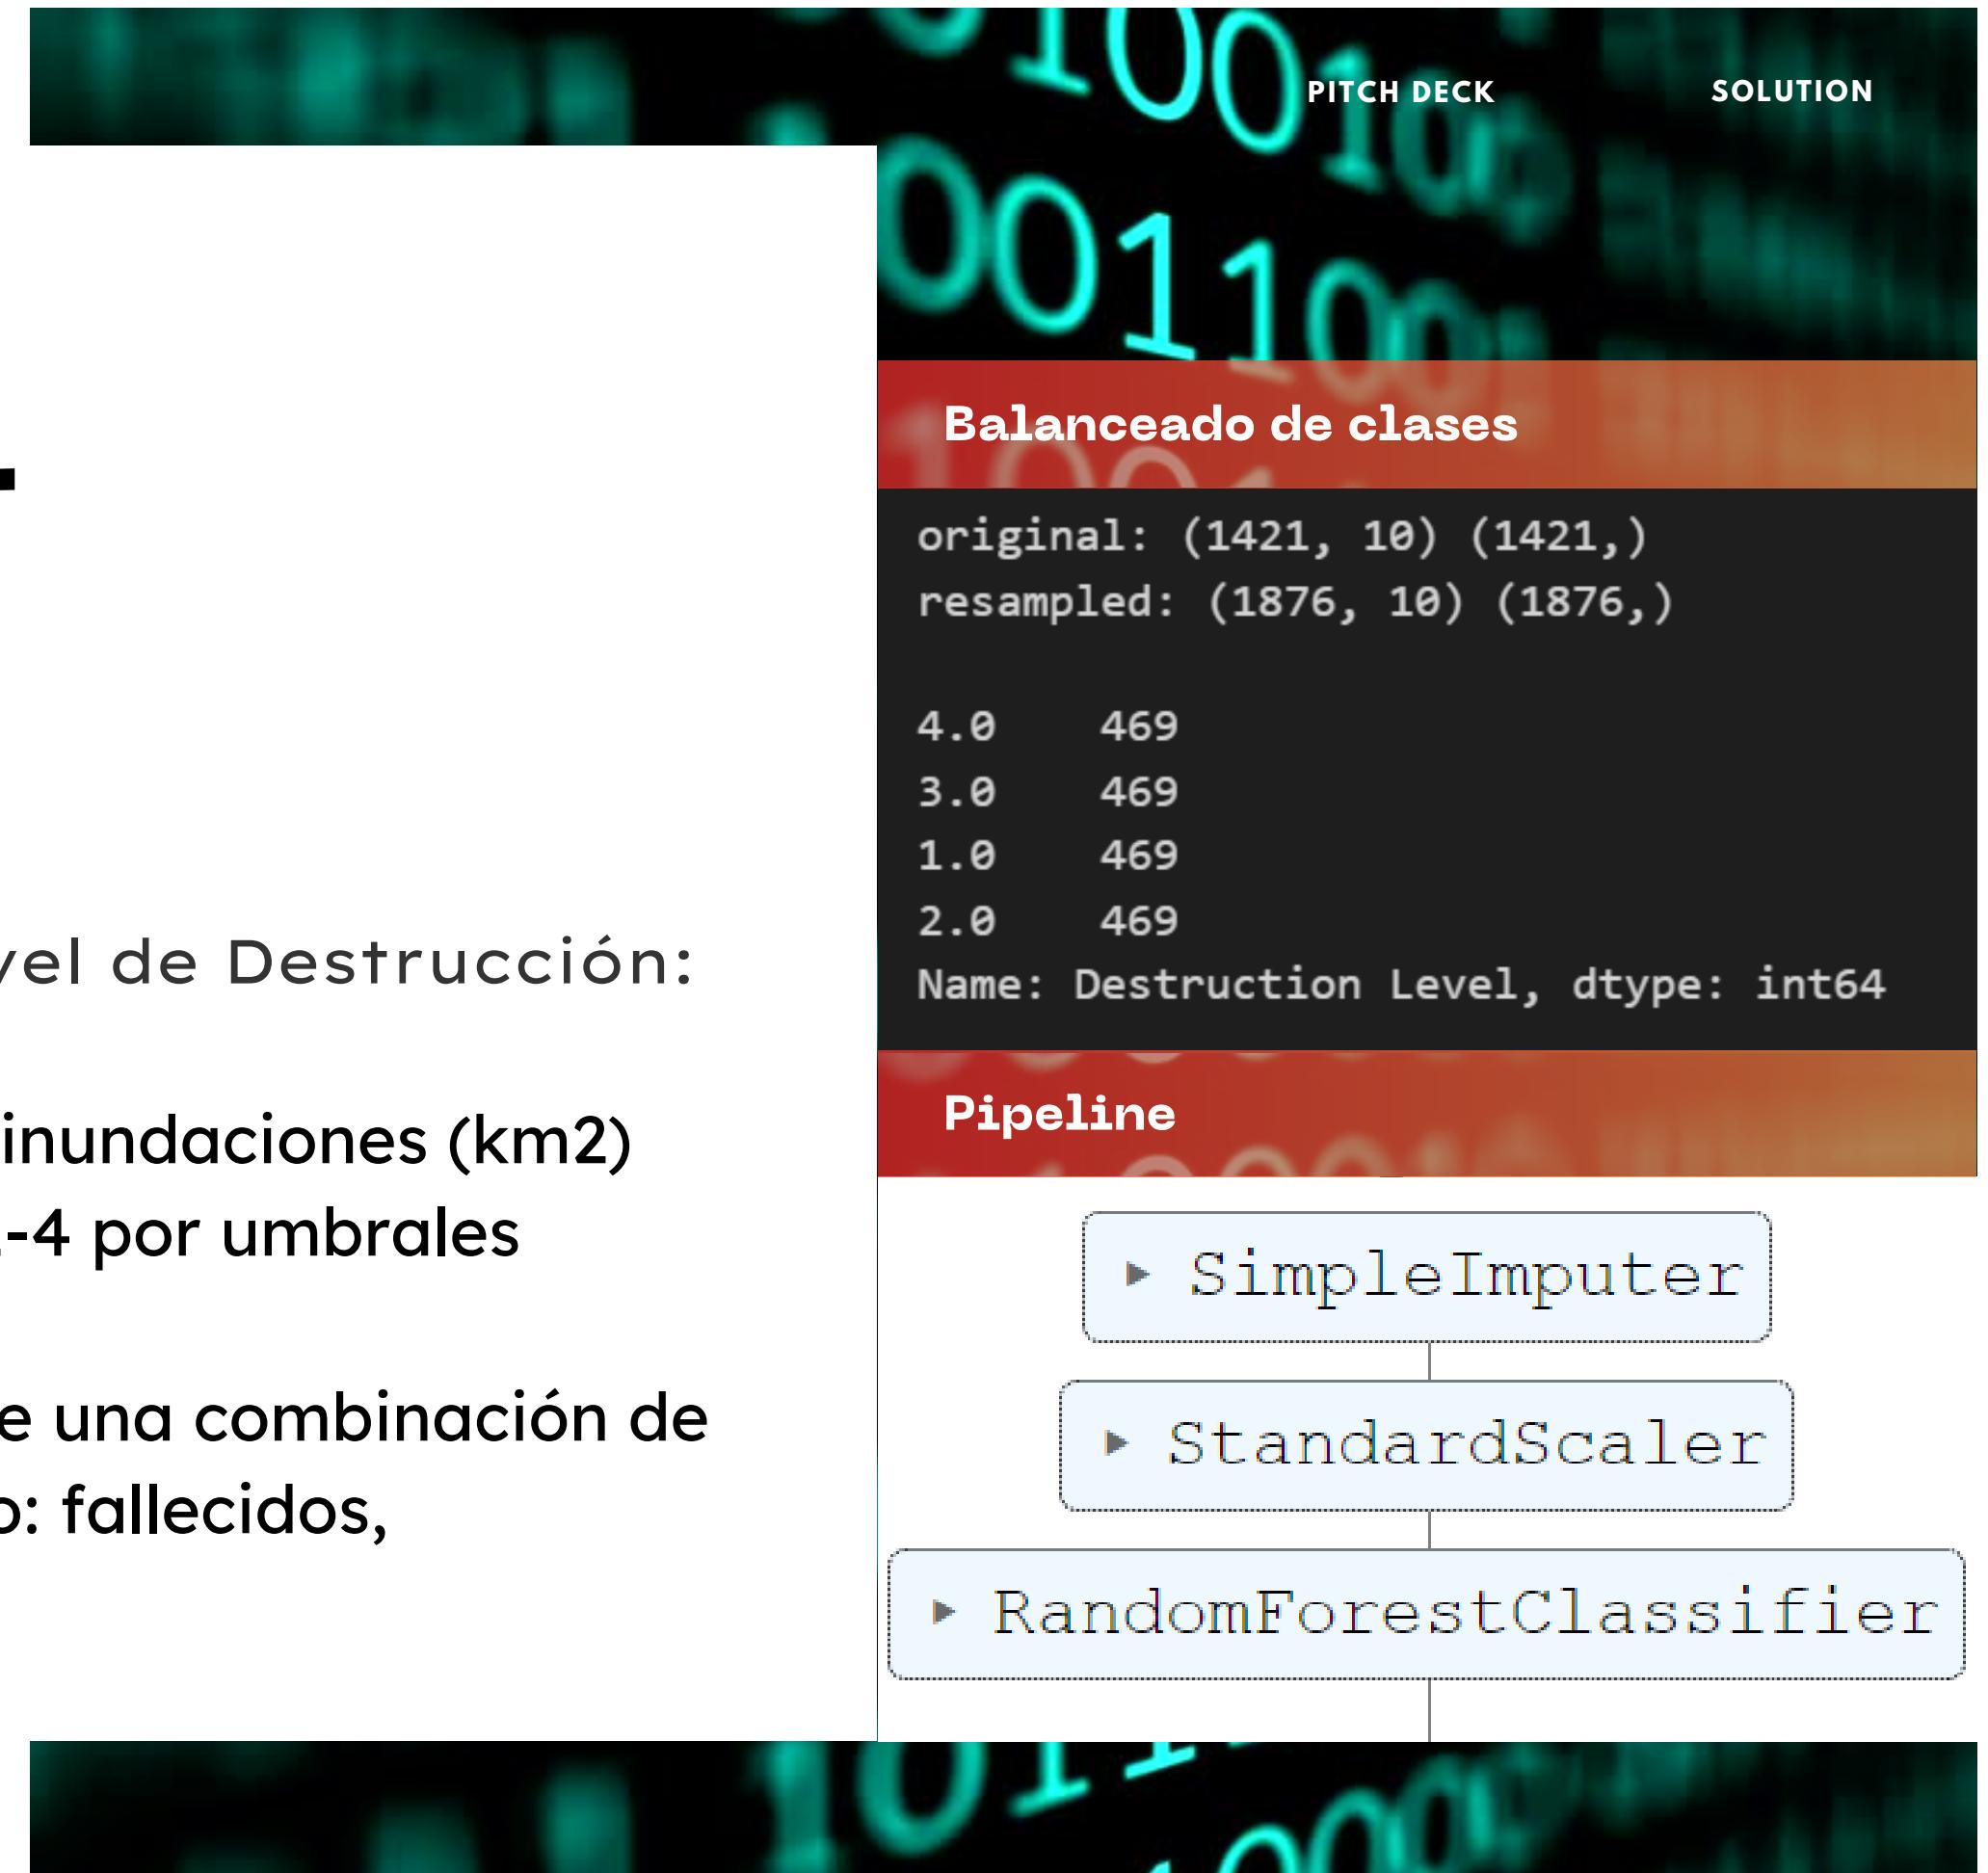
Herramientas



PROCESO DEL MODELO ML PREDICTIVO

Prototipo para anticipar el Nivel de Destrucción:

- Basado en Valor de Magnitud de inundaciones (km²)
- Definición de clasificaciones del 1-4 por umbrales basados en cuartiles.
- Función para asignar a cada clase una combinación de máximos de cada tipo de impacto: fallecidos, afectados y daños.



MODELO PREDICTIVO

```
# Filtro principal para Flood
df_flood = df[df['Disaster Type'] == 'Flood']
filter = df_flood['Dis Mag Value'] != 0
df_flood_filtered = df_flood[filter]
df_flood_filtered.head()
```

Filtros

```
type1_threshold = np.percentile(df_flood_filtered['Dis Mag Value'], 25)
type2_threshold = np.percentile(df_flood_filtered['Dis Mag Value'], 50)
type3_threshold = np.percentile(df_flood_filtered['Dis Mag Value'], 75)
print(f'Umbral 1: {type1_threshold}')
print(f'Umbral 2: {type2_threshold}')
print(f'Umbral 3: {type3_threshold}')
```

Umbrales por cuartiles

```
# Función previa que no considera valores nulos
def assign_flood_type(row):
    if row['Dis Mag Value'] < type1_threshold and row['Total Deaths'] < 100 and row['Total Affected'] < 10000 and row['Total Damages Adj'] < 1000000:
        return 'Low' # 1
    elif row['Dis Mag Value'] < type2_threshold and row['Total Deaths'] < 500 and row['Total Affected'] < 100000 and row['Total Damages Adj'] < 10000000:
        return 'Moderate' # 2
    elif row['Dis Mag Value'] < type3_threshold and row['Total Deaths'] < 1000 and row['Total Affected'] < 50000 and row['Total Damages Adj'] < 100000000:
        return 'High' # 3
    else:
        return 'Very High' # 4
```

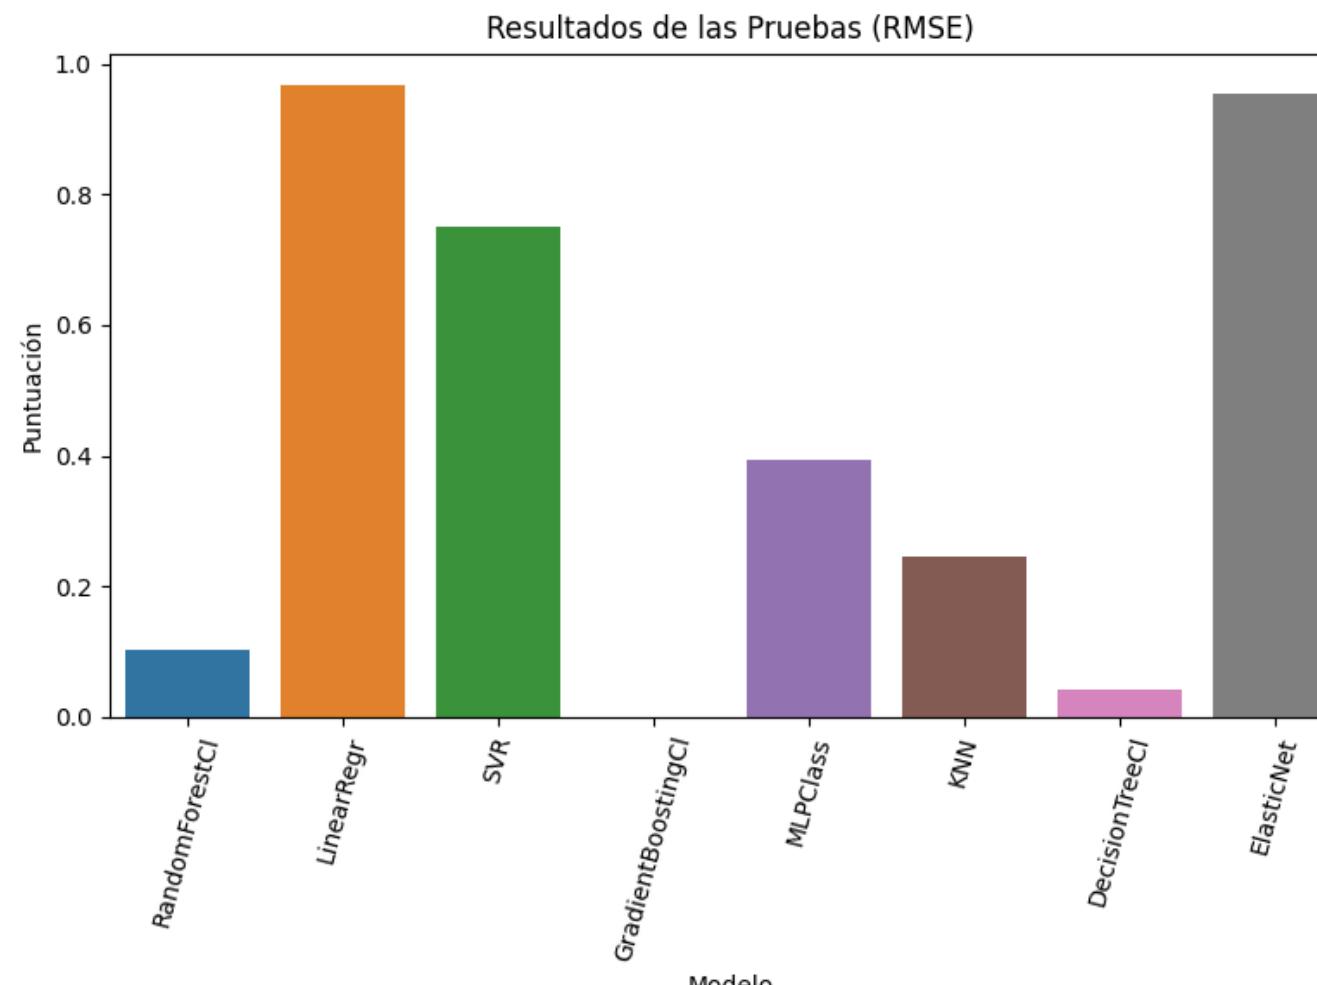
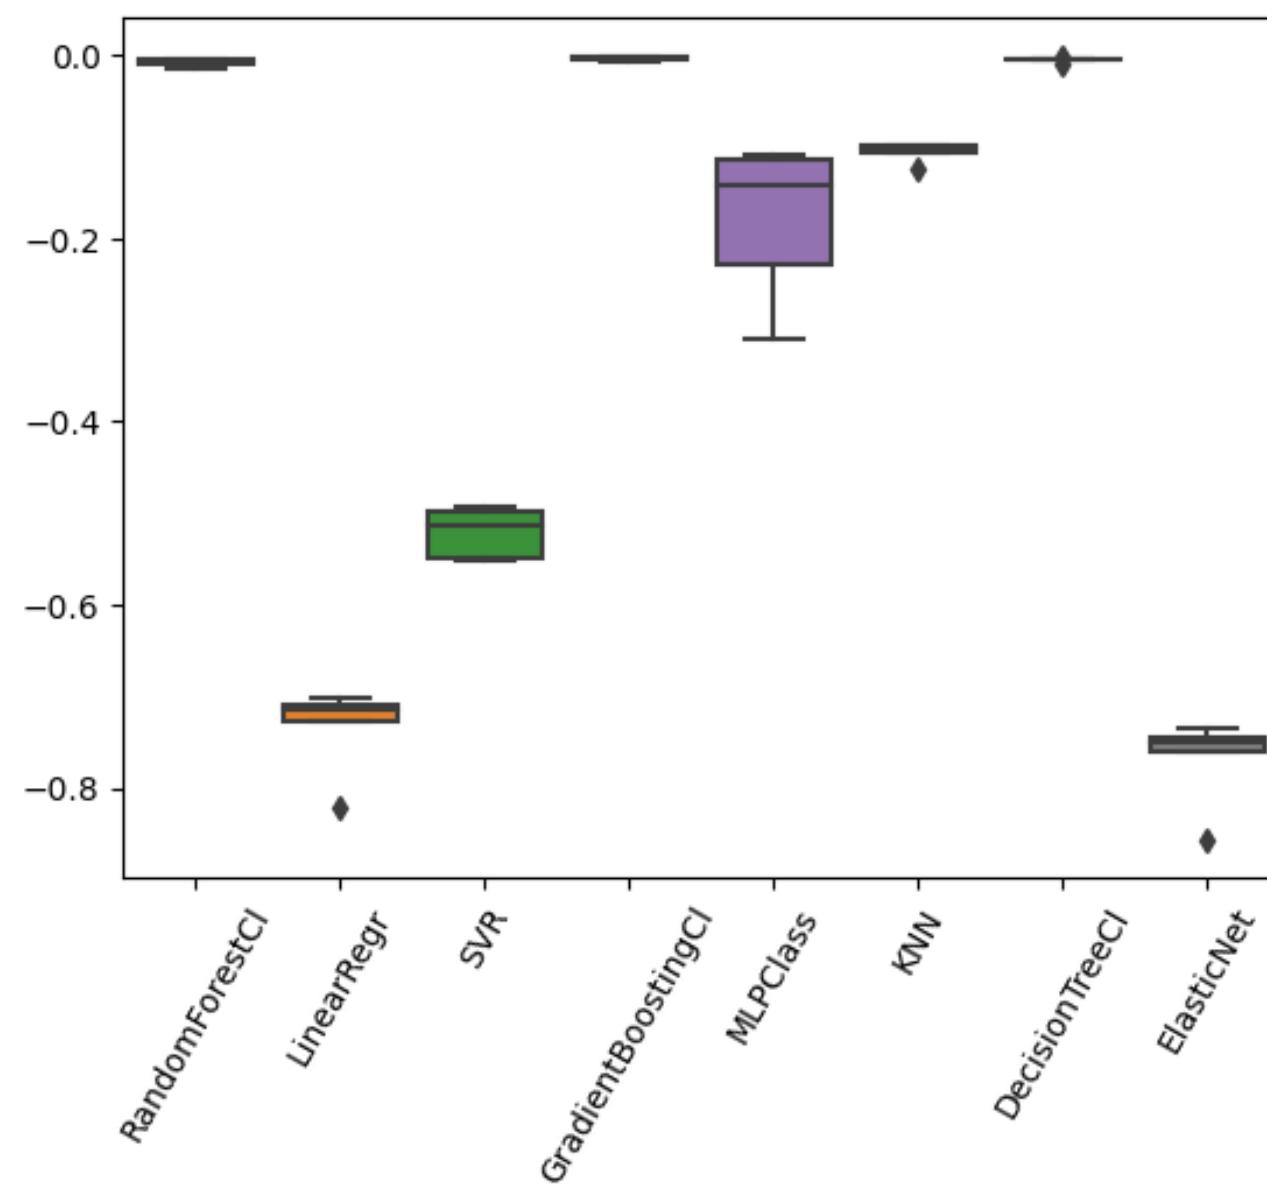
Función asignar clases Low, Moderate, High y Very High

```
floodtype_to_encode = df_flood_filtered['Flood Type'].values.reshape(-1, 1)
ordered_categories = ['Low', 'Moderate', 'High', 'Very High']
encoder = OrdinalEncoder(categories=[ordered_categories])
df_flood_filtered['Destruction Level'] = encoder.fit_transform(floodtype_to_encode) + 1
df_flood_encoded = df_flood_filtered.copy()
df_flood_encoded.head(10)
```

OrdinalEncoder clases 1–4 Destruction Level

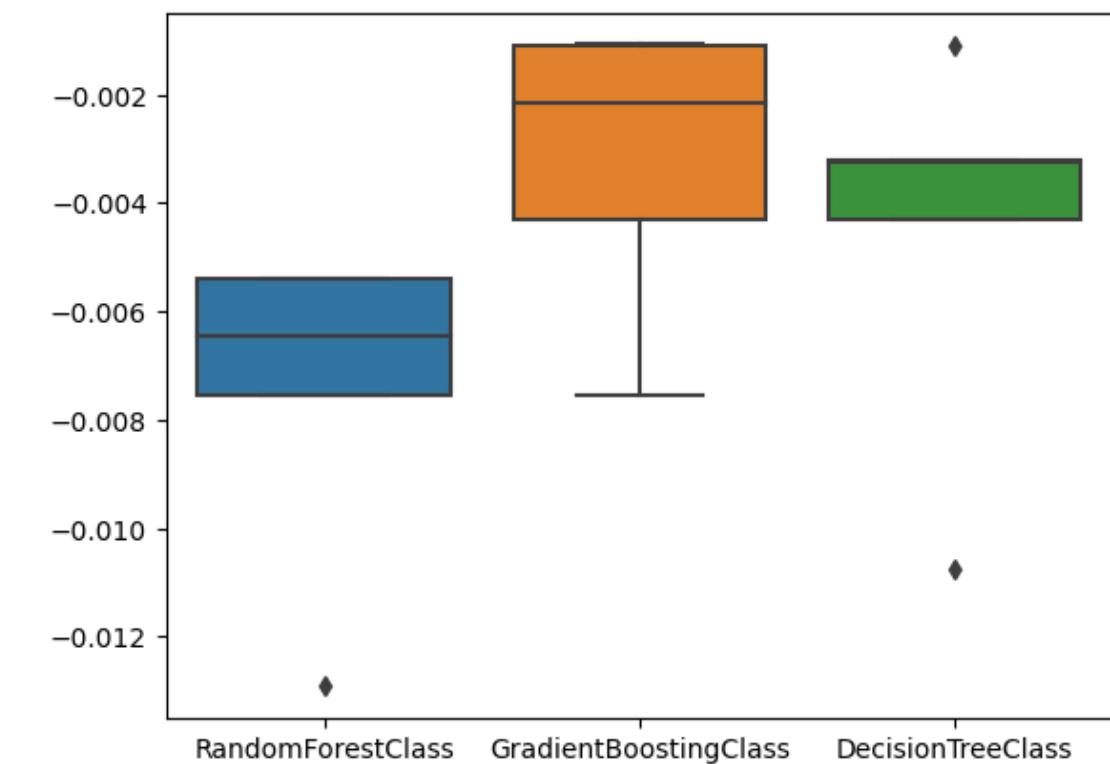
VALIDACIÓN DE ALGORITMOS

Análisis comparativo



Modelos finalistas:

RandomForestClassifier
GradientBoostingClassifier
DecisionTrees



PREDICCIÓN DE NIVEL DE DESTRUCCIÓN

Modelo ML con Random Forest Classifier

```
# Evaluar desempeño del dataset
print("Reporte de clasificación:")
print(classification_report(y_pred, y_pred))
```

Reporte de clasificación:

	precision	recall	f1-score	support
1.0	1.00	1.00	1.00	33
2.0	1.00	1.00	1.00	114
3.0	1.00	1.00	1.00	98
4.0	1.00	1.00	1.00	111
accuracy			1.00	356
macro avg	1.00	1.00	1.00	356
weighted avg	1.00	1.00	1.00	356

RESULTADOS DE CLASSIFICATION REPORT

Métricas colectivas de nivel de precisión y capacidad predictiva:

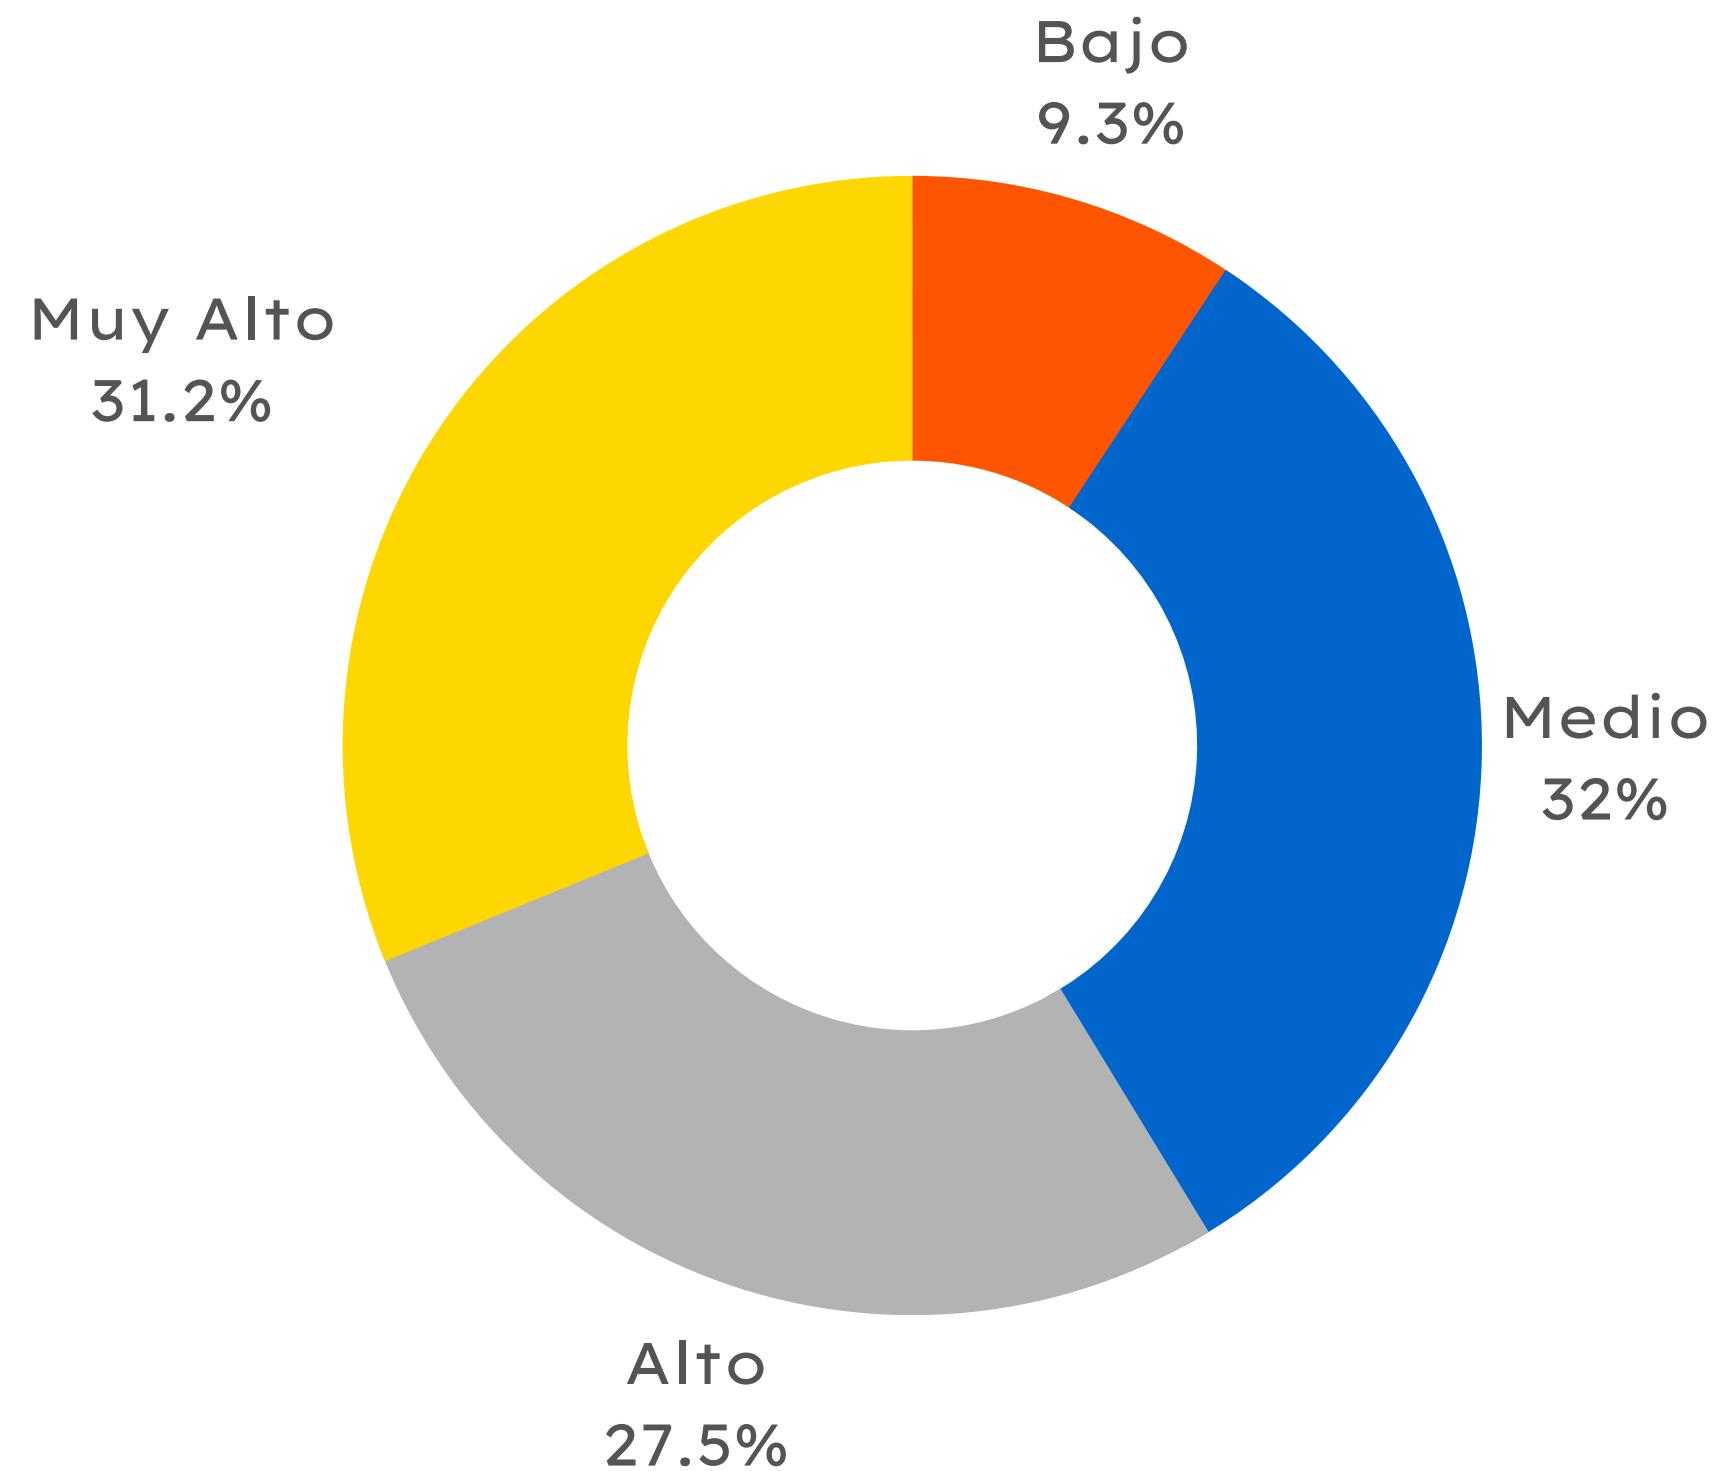
MUY ALTA

Diagnóstico:

- 1) Posible overfitting.
- 2) Escasez de datos para niveles Bajo y Alto.
- 3) Entrenar con menos columnas.
- 4) Necesario ajustar umbrales con percentiles también en columnas de impacto.
- 5) Explorar otra configuración para umbrales no basada en estadística.

INUNDACIONES Y_PRED

PREDICCIÓN DEL NIVEL DE DESTRUCCIÓN



DESASTRES NATURALES

MODELO PREDICTIVO: TESTS

Test A: Controlado

```
X_destruction_controlled= pd.DataFrame({'Dis Mag Value': [10, 4500, 26000, 90000],  
                                         'Start Year': [2024, 2025, 2026, 2027],  
                                         'Start Month': [1, 5, 8, 12],  
                                         'Start Day': [6, 16, 24, 30],  
                                         'End Year': [2024, 2025, 2026, 2027],  
                                         'End Month': [1, 5, 9, 1],  
                                         'End Day': [8, 21, 4, 28],  
                                         'Total Deaths': [70, 250, 800, 10000],  
                                         'Total Affected': [5000, 25000, 300000, 1000000],  
                                         'Total Damages Adj': [200000, 5000000, 12000000, 101000000]  
                                         })  
  
X_destruction_controlled['Destruction Level'] = pipeline.predict(X_destruction_controlled)  
X_destruction_controlled
```

	Dis Mag Value	Start Year	Start Month	Start Day	End Year	End Month	End Day	Total Deaths	Total Affected	Total Damages Adj	Destruction Level
0	10	2024	1	6	2024	1	8	70	5000	200000	2.0
1	4500	2025	5	16	2025	5	21	250	25000	5000000	3.0
2	26000	2026	8	24	2026	9	4	800	300000	12000000	3.0
3	2	2027	12	30	2027	1	28	10	10	10	2.0

Dataset Controlado o Test A:

	precision	recall	f1-score	support
2	1.00	1.00	1.00	1
3	1.00	1.00	1.00	2
4	1.00	1.00	1.00	1
accuracy				1.00
macro avg	1.00	1.00	1.00	4
weighted avg	1.00	1.00	1.00	4

Métricas de nivel de precisión y capacidad predictiva en Classification Report:

MUY ALTA

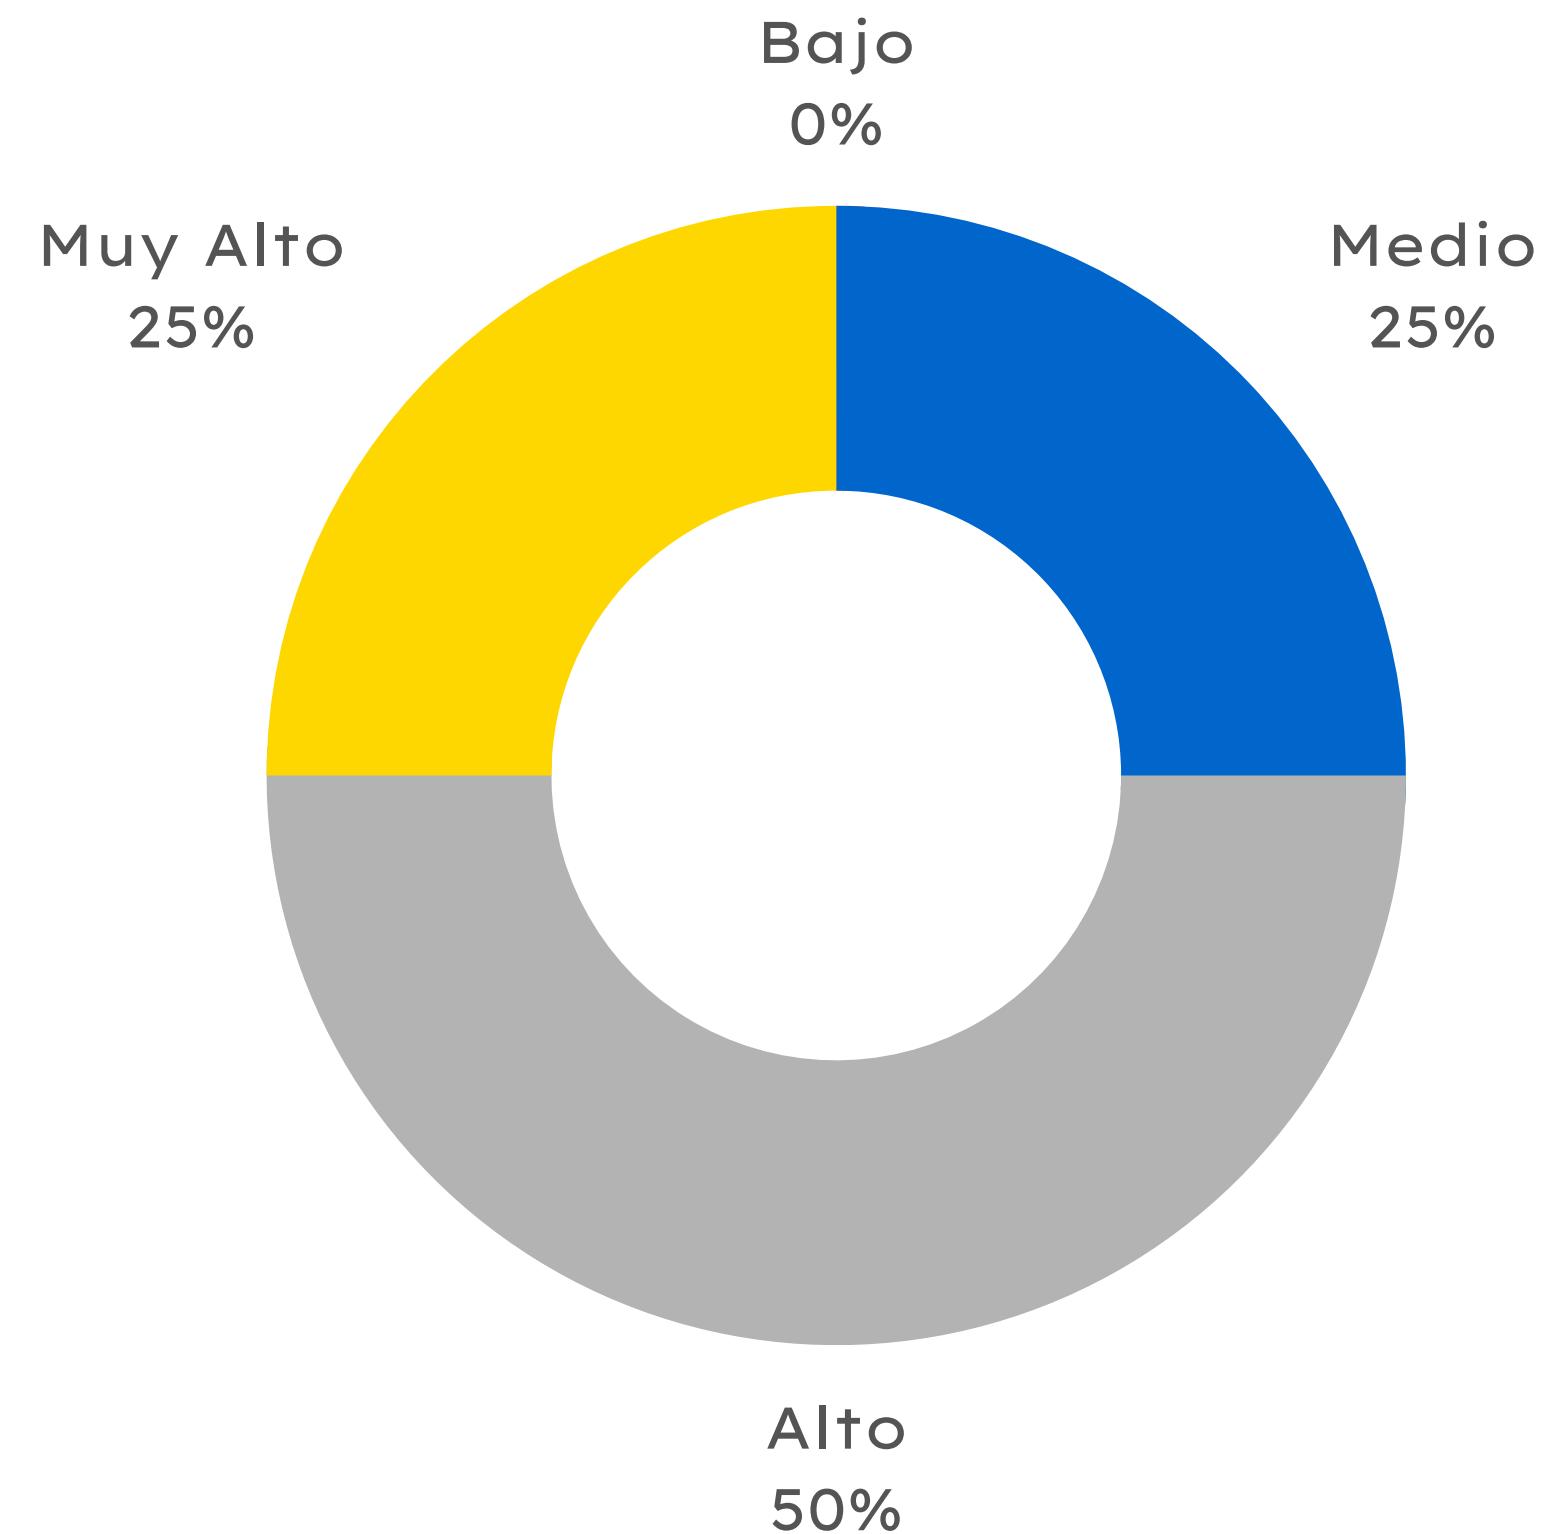
- Generaliza bien con datos desconocidos, demostrando precisión y recall del 100% en el conjunto de prueba.
- Resultados de test controlado sugieren su utilidad para clasificar niveles de destrucción en situaciones reales, a excepción de clase baja.
- El modelo se comporta adecuadamente y podría ser una herramienta valiosa para predicciones precisas con nuevos datos.

DESASTRES NATURALES

MODELO PREDICTIVO

INUNDACIONES TEST A

PREDICCIÓN DEL NIVEL DE DESTRUCCIÓN



DESASTRES NATURALES

MODELO PREDICTIVO: TESTS

Test B: Outliers

```
X_destruction_outliers = pd.DataFrame({'Dis Mag Value': [10, 4500, 26000, 2], # se cambió  
                                         'Start Year': [2024, 2025, 2026, 2027],  
                                         'Start Month': [1, 5, 8, 12],  
                                         'Start Day': [6, 16, 24, 30],  
                                         'End Year': [2024, 2025, 2026, 2027],  
                                         'End Month': [1, 5, 9, 1],  
                                         'End Day': [8, 21, 4, 28],  
                                         'Total Deaths': [70, 250, 800, 10], # se quitaron 0s  
                                         'Total Affected': [5000, 25000, 300000, 10], # se quitaron 0s  
                                         'Total Damages Adj': [200000, 5000000, 12000000, 10] # se qui  
                                         })  
  
X_destruction_outliers['Destruction Level'] = pipeline.predict(X_destruction_outliers)  
X_destruction_outliers
```

	Dis Mag Value	Start Year	Start Month	Start Day	End Year	End Month	End Day	Total Deaths	Total Affected	Total Damages Adj	Destruction Level
0	10	2024	1	6	2024	1	8	70	5000	200000	2.0
1	4500	2025	5	16	2025	5	21	250	25000	5000000	3.0
2	26000	2026	8	24	2026	9	4	800	300000	12000000	3.0
3	2	2027	12	30	2027	1	28	10	10	10	2.0

Outliers Dataset o Test B:

	precision	recall	f1-score	support
1	0.00	0.00	0.00	1
2	0.50	1.00	0.67	1
3	1.00	1.00	1.00	2
accuracy			0.75	4
macro avg	0.50	0.67	0.56	4
weighted avg	0.62	0.75	0.67	4

Métricas de nivel de precisión y capacidad predictiva en Classification Report:

BAJO

- Dificultades en clasificar la clase 1, obteniendo precisión y recall de 0.
- Buena capacidad predictiva para las clases 2 y 3, con precisión y recall del 50% y 100% respectivamente. Precisión promedio para Test B con outliers es del 62%, indicando que el modelo se desempeña de manera aceptable en general, pero tiene dificultades con datos atípicos o fuera de rango.
- Importante tener en cuenta que, en los desastres naturales, pueden presentarse casos poco comunes o excepcionales.

DESASTRES NATURALES

MODELO PREDICTIVO: TESTS

Test C: Low

```
X_destruction_low = pd.DataFrame({
    'Dis Mag Value': [5, 3000, 1500, 1], # Valores 'Dis Mag Value' reducidos
    'Start Year': [2024, 2025, 2026, 2027],
    'Start Month': [1, 5, 8, 12],
    'Start Day': [6, 16, 24, 30],
    'End Year': [2024, 2025, 2026, 2027],
    'End Month': [1, 5, 9, 1],
    'End Day': [8, 21, 4, 28],
    'Total Deaths': [35, 150, 2, 5], # Valores 'Total Deaths' reducidos
    'Total Affected': [2500, 12000, 8, 5], # Valores 'Total Affected' reducidos
    'Total Damages Adj': [100000, 3000000, 6, 5] # Valores 'Total Damages Adj' reducidos
})
X_destruction_low['Destruction Level'] = pipeline.predict(X_destruction_low)
X_destruction_low
```

	Dis Mag Value	Start Year	Start Month	Start Day	End Year	End Month	End Day	Total Deaths	Total Affected	Total Damages Adj	Destruction Level
0	5	2024	1	6	2024	1	8	35	2500	100000	2.0
1	3000	2025	5	16	2025	5	21	150	12000	3000000	2.0
2	1500	2026	8	24	2026	9	4	2	8	6	1.0
3	1	2027	12	30	2027	1	28	5	5	5	2.0

	precision	recall	f1-score	support
1	0.00	0.00	0.00	2
2	0.00	0.00	0.00	0
3	1.00	1.00	1.00	1
4	0.00	0.00	0.00	1
accuracy			0.25	4
macro avg	0.25	0.25	0.25	4
weighted avg	0.25	0.25	0.25	4

Métricas de nivel de precisión y capacidad predictiva en Classification Report:

INSUFICIENTE

- Dificultades en clasificar la clase 1 y 2, obteniendo precisión y recall de 0 para esta.
- Buena capacidad predictiva para la 3, con precisión y recall del 100%.

A tener en cuenta:

- No se metieron valores para clase 4 Muy Alta, por tanto, no la clasificó.
- En el caso de desastres naturales de impacto bajo son menos alarmantes y quizás por eso no se recolectan.

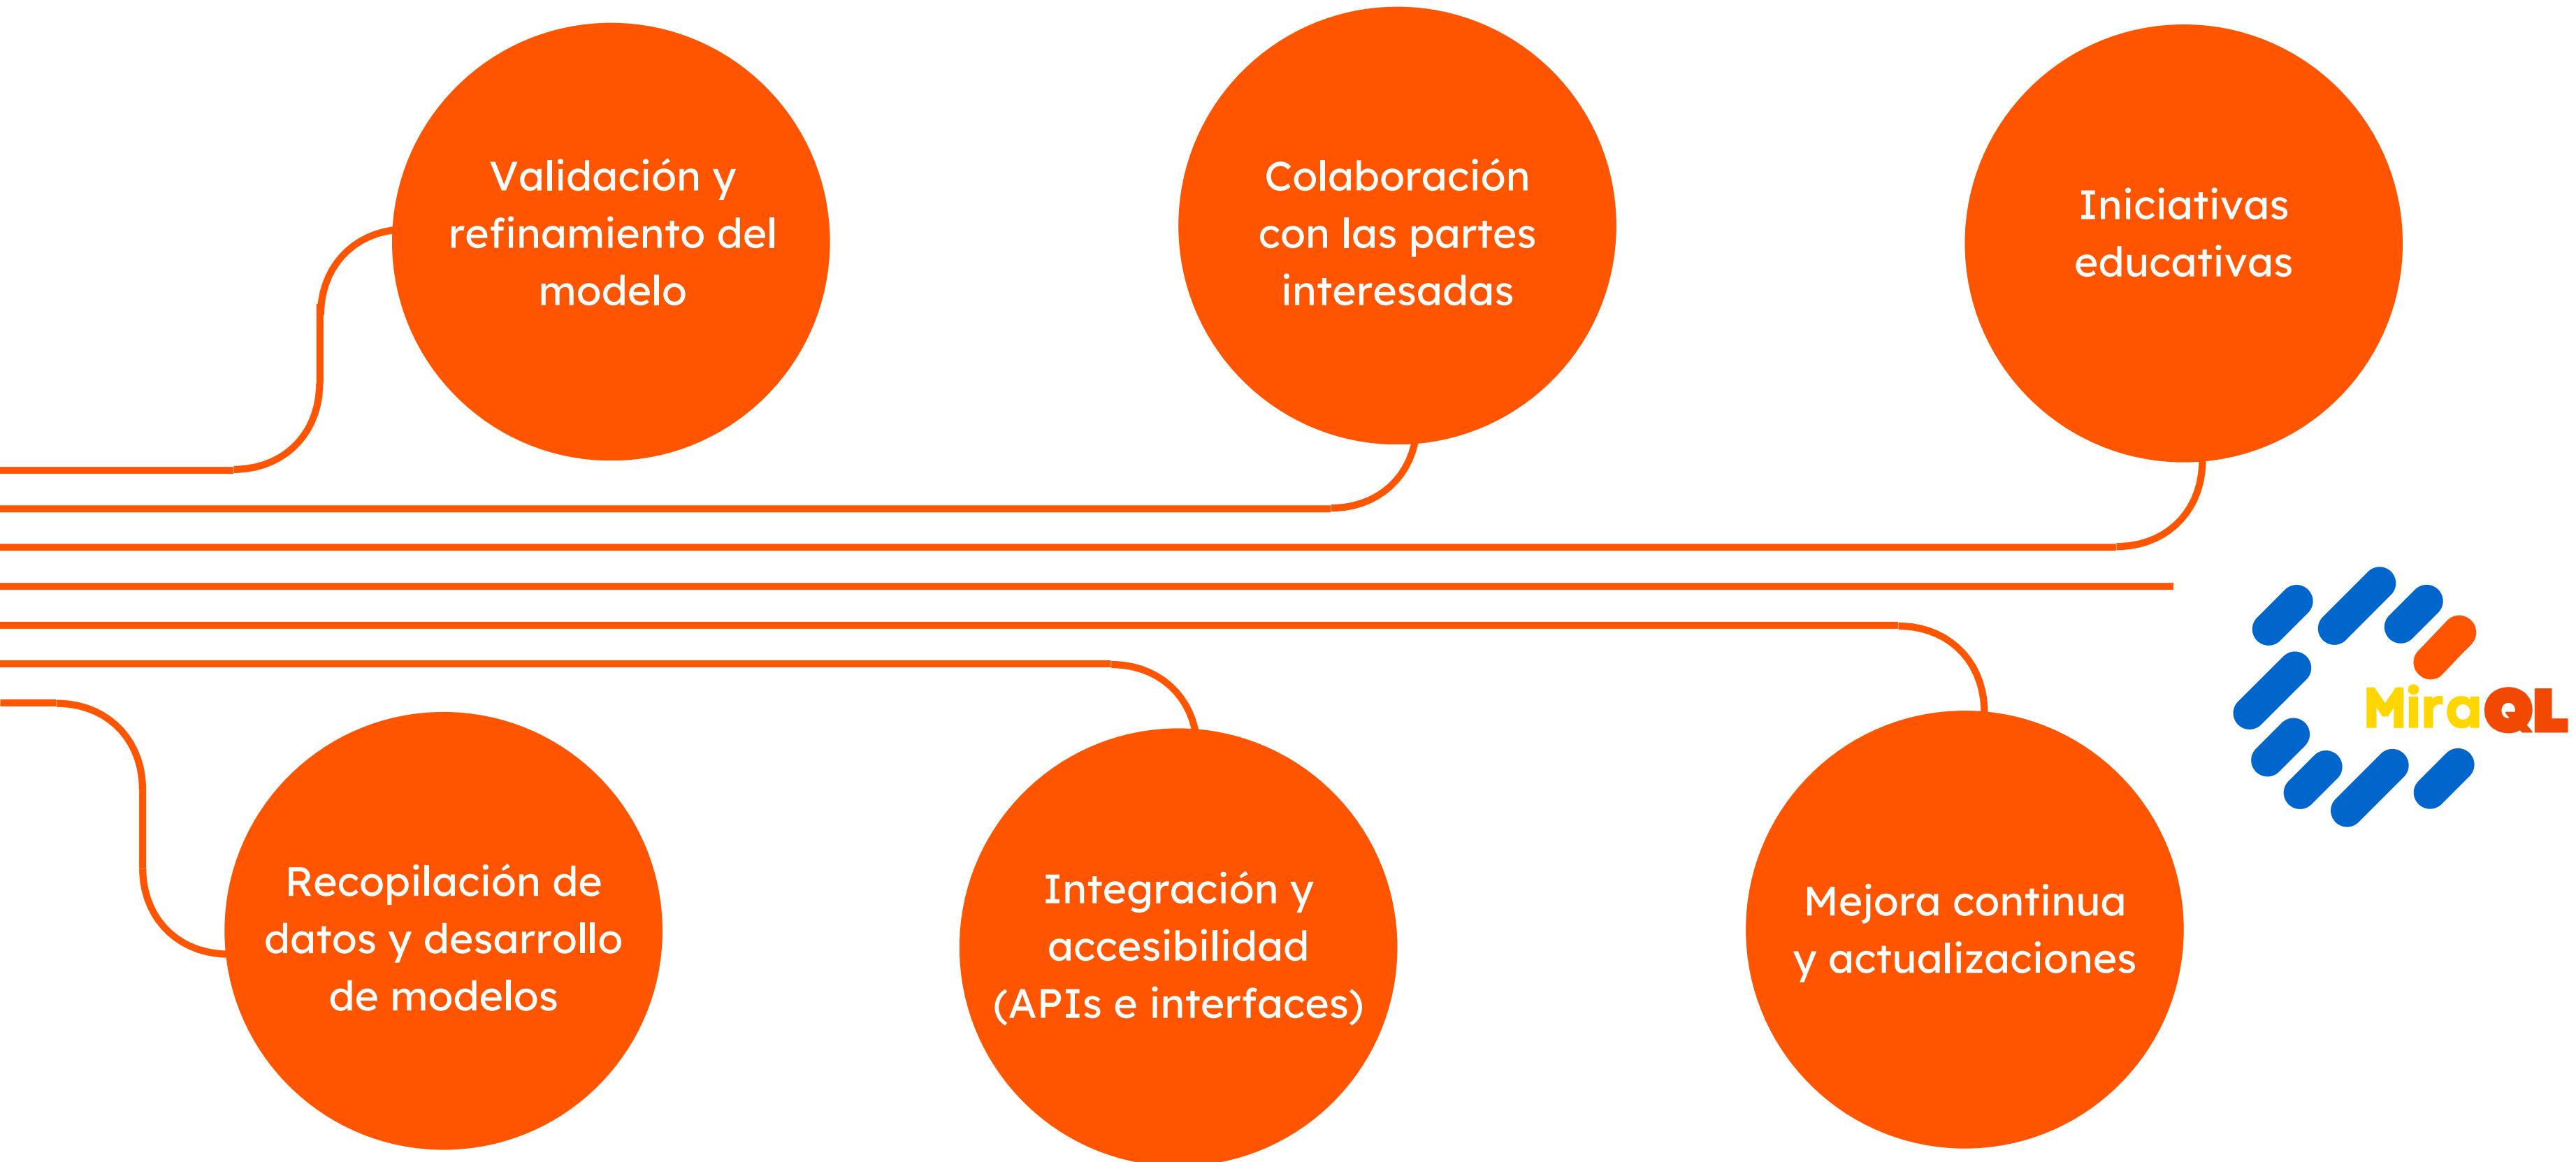
RECOMENDACIONES

Mejora de resultados de predicciones

- Más pruebas con datos nuevos de mayor volumen.
- Aplicar percentiles en distribución de umbrales de columnas de impacto.
- Preprocesado con menos etiquetas para X.
- Pipeline con modelos finalistas validados con desempeño alto como DecisionTrees y GradientBoostingClassifier.
- Nuevos ajustes a hiperparámetros.
- Iteración y reportes de clasificación de tests.

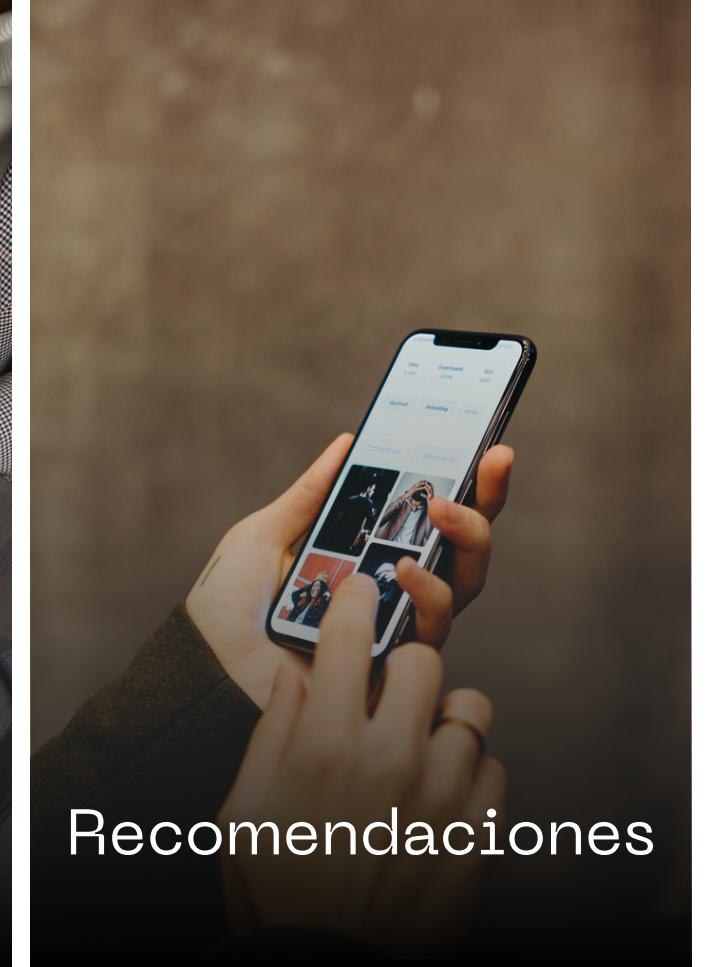
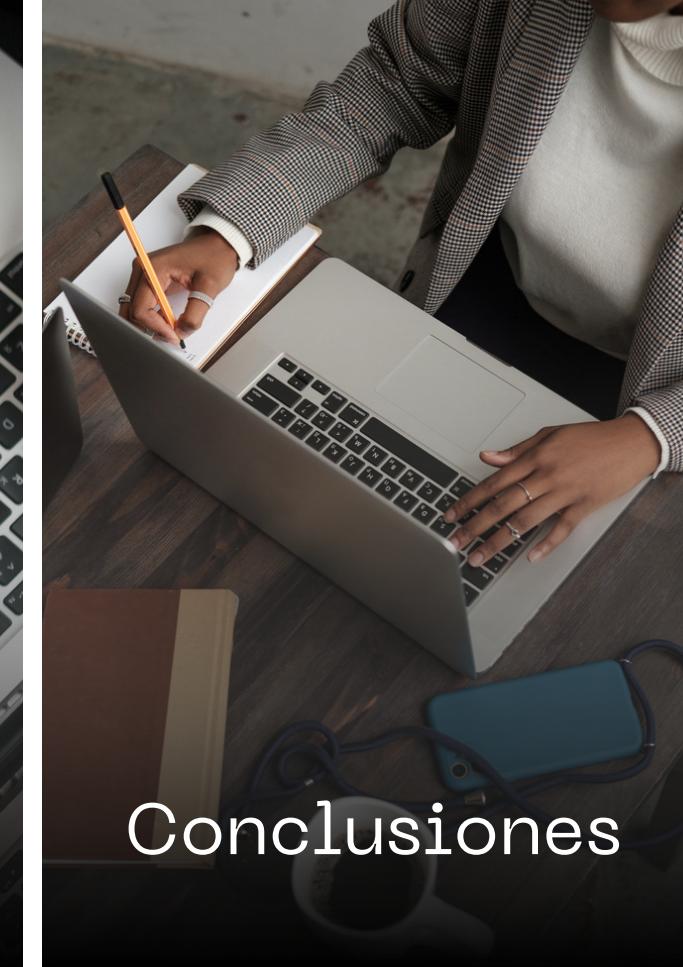
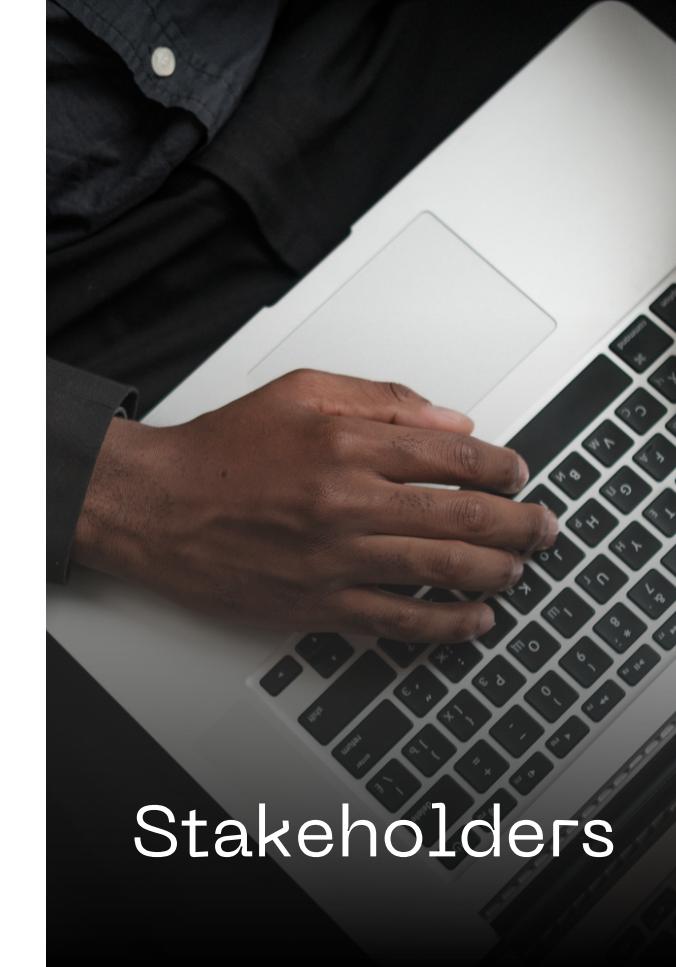
DESASTRES NATURALES CONCLUSIONES

IMPLEMENTACIÓN DEL MODELO PREDICTIVO



DESASTRES NATURALES
CONCLUSIONES

**MODELO DE
NEGOCIO,
CONCLUSIONES Y
RECOMENDACIONES**



DESASTRES NATURALES

MODELO DE NEGOCIO EN CANVAS



Convenios de colaboración público-privada

- Administraciones públicas.
- Universidades.
- Agencias de recolección de datos sobre desastres.
- NASA y otras agencias aeroespaciales de observación metereológica satelital.
- Comunidades en riesgo.

KEY ACTIVITIES

- Consultoría BI.
- EDA.
- Diseño de Dashboards.
- CRISP-DM a BBDD sobre desastres naturales.
- Adaptación del modelo predictivo a diferentes tipos de desastres y regiones.
- Capacitación en uso de herramientas.



KEY RESOURCES

- BBDD de instituciones reconocidas con una metodología de recolección confiable.
- Patentes de modelos predictivos.
- Inteligencia de negocio.

VALUE PROPOSITIONS

Estrategia y planificación

Innovación

Gestión de ayuda y optimización del rescate

BI y especificidad sobre riesgos

Predicción es igual a prevención, protección y resiliencia



COST STRUCTURE

- Hardware, licencias de software y actualización prof.
- Obtención de bases de datos de pago o por suscripción.
- Contratación de personal cualificado.
- Tecnología cloud para almacenamiento y gestión de grandes volúmenes de datos.
- Viáticos de desplazamiento para investigación en zonas en riesgo (en caso de que se requiera).
- Mejora continua de modelos y testing.



CUSTOMER RELATIONSHIPS

- In-company por consultoría y capacitación.
- Remotas para proyectos específicos como cualquier etapa de la metodología CRISP-DM EDA, dashboards, BI y ML.



CHANNELS

- Ferias y foros de tecnología de IA e inversión.
- In-company y remoto
- Blog, e-mail marketing y RRSS.
- Streaming para probar herramientas durante desastres naturales en tiempo real.



CUSTOMER SEGMENTS

- Administraciones públicas.
- Compañías de Seguros y Administradoras de Riesgos.
- Promoción Inmobiliaria.
- Cadena de Suministro y Logística.
- Desarrollo de Infraestructura y Planificación Urbana
- Servicios de Emergencia y Respuesta a Desastres.
- Comunidades y ONG.



*Partners pueden ser clientes, ya que aportan sus propios datos.

REVENUE STREAMS

Los clientes están dispuestos a pagar por:

- Tiempo es vida, no solo dinero.
- Minimización de desastres.
- Planificación de la reconstrucción en zonas de menor o cero impacto.
- Gestión y mejora continua de los modelos predictivos y la transformación de los datasets.
- Soluciones globales y regionales.



DIRIGIDO A:

**GOBIERNOS Y AGENCIAS
DE GESTIÓN DE
DESASTRES**



Estrategia

Mejorar estrategias de prevención, mitigación y respuesta.

**EMPRESAS
DE SEGUROS**



Especificidad sobre riesgos

Integrar en procesos de suscripción y evaluación de riesgos para ofrecer pólizas más precisas y ajustadas a riesgos específicos de cada región.

**EMPRESAS DE
CONSTRUCCIÓN E
INFRAESTRUCTURA**



Resiliencia

Identificar zonas de alto riesgo y diseñar edificaciones e infraestructuras resistentes.

**ORGANIZACIONES
DE AYUDA
HUMANITARIA**



Gestión de ayuda

Anticipar y preparar recursos y dirigir la ayuda hacia las áreas más afectadas.

**COMUNIDADES
VULNERABLES**



Protección

Preparación ante el riesgo y toma de decisiones informadas sobre la protección y evacuación.

IMPLEMENTACIÓN

- Recopilar datos de calidad, preferiblemente segmentados por tipo de desastre.
- Validar y refinar el modelo utilizando datos de pruebas para garantizar su precisión y confiabilidad.
- Integración y Accesibilidad para empresas y administraciones a través de interfaces o API fáciles de usar para consultar nuevos datos y obtener predicciones en tiempo real.
- Colaborar con las partes interesadas para demostrar el valor del modelo y fomentar su adopción.
- Comprender las necesidades comerciales específicas y adaptar la salida del modelo para adaptarse a diferentes industrias.



DESASTRES NATURALES

PROCESO DE MEJORA CONTINUA

BENEFICIOS DE MEJORAS

MAYOR PRECISIÓN:

- Con más variables de correlación, el modelo podrá hacer predicciones más precisas y realistas sobre la destrucción causada por inundaciones.

PLANIFICACIÓN EFICIENTE:

- Los gobiernos y las agencias de gestión de desastres podrán planificar mejor las medidas de prevención, mitigación y respuesta en función de los patrones geográficos y temporales identificados por el modelo.

RESPUESTA RÁPIDA:

- La recolección de datos de geolocalización mejorada permitirá una respuesta más rápida y efectiva en situaciones de emergencia, lo que puede salvar vidas y reducir los daños.

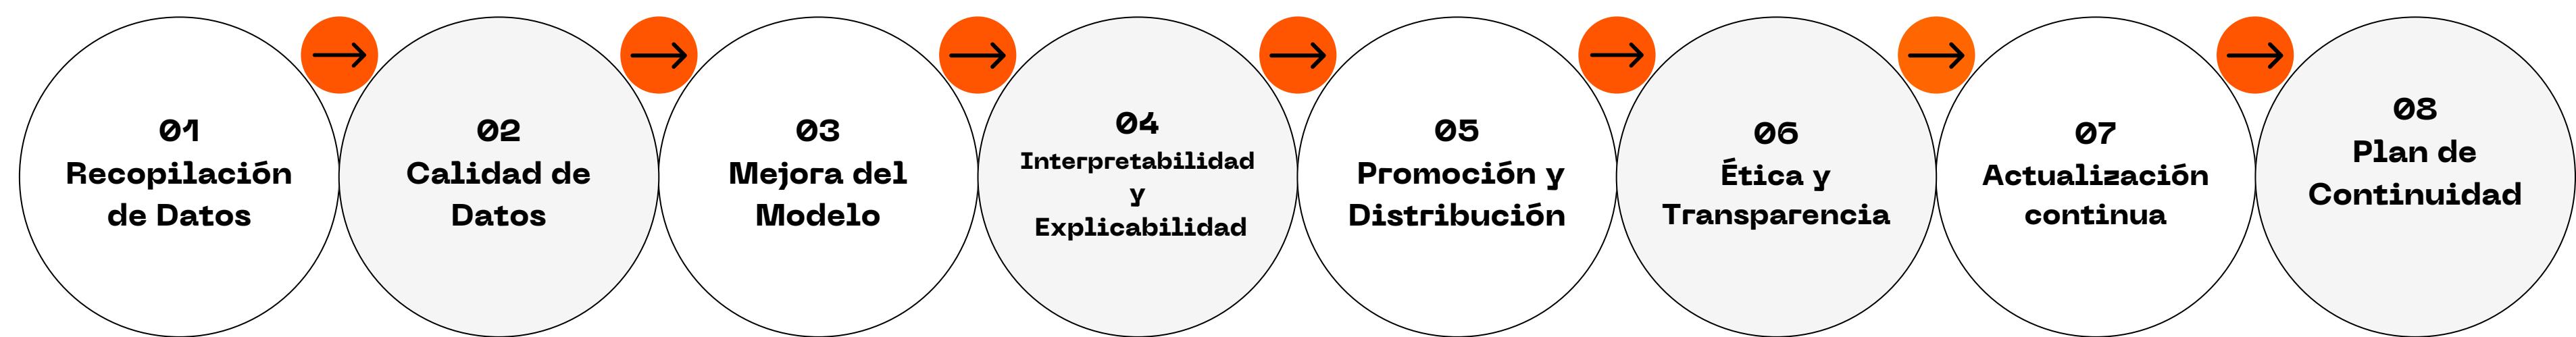
ADAPTABILIDAD A DIFERENTES ESCENARIOS:

- Con datos sobre diferentes tipos de desastres y su interacción, el modelo podrá adaptarse a una amplia gama de escenarios complejos y evaluar su impacto combinado.



DESASTRES NATURALES

RECOMENDACIONES DE MEJORA CONTINUA



- Fuentes confiables y actualizadas. Colaborar con agencias gubernamentales, organizaciones de gestión de desastres y expertos en el campo para obtener datos precisos y detallados.
- Sistemas de monitoreo y registro de datos estandarizados y completos.
- Limpiar y preprocessar datos para eliminar valores atípicos, datos faltantes o incoherentes que puedan afectar la precisión del modelo, si procede.
- Verificar y validar la calidad de los datos antes de utilizarlos para entrenar o actualizar el modelo.
- Considerar otras variables relevantes que puedan influir en el nivel de destrucción.
- Explorar diferentes algoritmos de aprendizaje automático y técnicas de modelado.
- Técnicas de validación cruzada y ajuste de hiperparámetros para evaluar y mejorar rendimiento.
- Asegurar que el modelo sea interpretable y explicable para que los stakeholders puedan comprender cómo se hacen las predicciones y confiar en los resultados.
- Proporcionar información clara sobre qué variables tienen mayor influencia en las predicciones de destrucción causada por las inundaciones.
- Identificar áreas geográficas más propensas a sufrir inundaciones y dirigir esfuerzos de promoción del producto hacia esas regiones.
- Establecer asociaciones con gobiernos locales, organizaciones de ayuda humanitaria y empresas de seguros para promover la adopción del modelo.
- Organizar talleres y presentaciones para mostrar beneficios.
- Ser transparente sobre cómo se utilizan los datos, cómo se entrena el modelo y cómo se generan las predicciones.
- Garantizar la privacidad y protección de datos personales según las regulaciones y normativas aplicables.
- Mantener actualizado con nuevos datos a medida que se recopilen y estén disponibles para que siga siendo relevante y preciso con el tiempo.
- Desarrollar un plan de continuidad para garantizar que el modelo y su infraestructura estén disponibles y funcionando durante situaciones de desastres, cuando más se necesiten.

DESASTRES NATURALES

RECOMENDACIONES

- Colaborar con científicos de datos, expertos en desastres naturales, empresas y autoridades gubernamentales.
- Consideraciones éticas sobre privacidad de datos y posibles sesgos en las predicciones del modelo.
- Combinar tecnología, experiencia y colaboración público-privada para abordar desafíos y mejorar sus estrategias de gestión de desastres.

BASE DE DATOS:

- Incorporar magnitudes de densidad demográfica, densidad de construcción y/o duración.
- Recopilar de forma normalizada y homogénea los datos sobre los diferentes desastres naturales.
- Definir medida de magnitud para las sequías y su correlación con las personas afectadas.
- Reforzar y apoyar entes como EMDAT (1988), OCHA(1991), UNISDR (1999).
- Mejorar infraestructuras y planes de emergencia.



DESASTRES NATURALES

EPÍLOGO

Los datos recopilados por el EMDAT sobre la ocurrencia e impacto de los desastres naturales nos revelan una dimensión desconocida por la mayor parte de la población mundial: la magnitud de los daños materiales y personas afectadas durante los últimos 120 años y sus impactos.

Cuando observamos la recurrencia en determinadas regiones, es imposible no pensar en las consecuencias de esos impactos para el desarrollo y evolución de la población (hambruna, epidemias, falta de agua potable y otros servicios) que sobrevive a duras penas, limitando con ellos las posibilidades de mejor calidad de vida y recuperación, cuando estos fenómenos son cíclicos.

Es fundamental impulsar modelos para detectar patrones y otros factores de ocurrencia que nos permitan anticipar desastres naturales de gran magnitud y con ello poder preparar planes de respuestas efectivos y expeditos de atención humanitaria; y en la medida de lo posible aprender a aprovechar la “energía” de esos fenómenos naturales en beneficio de la sociedad.

GRACIAS

CONTACTA CON EL EQUIPO

Elena Blanco

blancoelenal1@gmail.com

LinkedIn:
[@elenablancodataanalytics](https://www.linkedin.com/in/elenablancodataanalytics)

Alejandra Eng

criptolmin@gmail.com

LinkedIn:
[@alejandraengbroca](https://www.linkedin.com/in/alejandraengbroca)

Rafael De Marco

rdemarcoz@outlook.com

LinkedIn:
[@rafael-de-marco-z-53097014](https://www.linkedin.com/in/rafael-de-marco-z-53097014)

Ángel Bardon

bardon.angel@gmail.com

LinkedIn:
[@angel-bardon-diez](https://www.linkedin.com/in/angel-bardon-diez)